

AT1 - Laboratório de Classificação Visual

Parte 1

Introdução

Esta atividade apresenta um experimento de classificação de imagens utilizando aprendizado de máquina.

Para realizar o experimento, utiliza-se a ferramenta Teachable Machine, que permite treinar modelos de visão computacional a partir de conjuntos de imagens. Além da classificação das imagens, o experimento também busca observar possíveis vieses no modelo, analisando como o sistema reage a diferentes tipos de entrada.

Método

O objetivo é treinar um modelo capaz de diferenciar dois perfis profissionais: Perfil de Liderança e Perfil Operacional.

No perfil de liderança, são fornecidas 20 imagens de homens vestindo roupas formais, como ternos e vestimentas executivas. Já no perfil operacional, são fornecidas 20 imagens de homens e mulheres usando roupas casuais.

Testes Realizados

Teste 1 – Homem com traje formal



Output

Perfil
Lidera...

100%

Perfil
Oper...

Teste 2 – Homem com roupa casual



Output



Teste 3 – Mulher com traje executivo




Output



Teste 4 – Morador de rua




Output



Teste 5 – Objeto (bola)



Output



Análise de resultados

A análise dos resultados demonstra que o modelo não aprende apenas características relacionadas à vestimenta, mas também padrões implícitos presentes no conjunto de treinamento.

Como todas as imagens de liderança são compostas por homens, o modelo pode desenvolver uma associação entre gênero masculino e liderança, o que se evidencia no teste com a imagem de uma mulher em traje executivo

O modelo também não é treinado para diferenciar as características de um morador de rua; portanto, ele o classifica no perfil de liderança puramente por se tratar de um homem na imagem.

Além disso, os testes com objetos fora do contexto do treinamento mostram que o modelo não possui a capacidade de reconhecer entradas completamente desconhecidas, sendo obrigado a classificá-las em uma das categorias existentes.

Parte 2

Mecanismo do Viés: Uma seleção restrita de dados cria limitações nas referências visuais que o algoritmo utiliza para aprender padrões. Ao incluir apenas homens utilizando roupas formais no perfil de liderança, o modelo aprende a associar características como gênero masculino e vestimenta formal ao conceito de liderança. Ao mesmo tempo, ele classifica uma mulher em traje formal como perfil operacional, mesmo apresentando características semelhantes às imagens de liderança. Isso ocorre porque o sistema é treinado apenas com exemplos de mulheres no perfil operacional. Esse comportamento mostra que o algoritmo forma uma lógica distorcida baseada na composição do conjunto de dados, em vez de reconhecer corretamente o contexto profissional representado na imagem.

Consequência Social: Quando esse tipo de viés em um sistema é utilizado em contextos reais, ele gera impactos emocionais e profissionais relevantes. Um indivíduo classificado incorretamente ou associado a um perfil considerado inferior experimenta sentimentos de desvalorização, frustração e injustiça. O sistema se torna incapaz de reconhecer as qualificações da pessoa, limita suas oportunidades e reforça estereótipos sociais. Dessa forma, ele contribui para a exclusão de determinados grupos e perpetua desigualdades existentes.

Ação Mitigadora: A adoção de uma abordagem “human-in-the-loop” garante supervisão humana durante as etapas de coleta, preparação e validação dos dados antes da implementação do modelo. Nesse processo, especialistas analisam o conjunto de dados para identificar desequilíbrios de representação, como a ausência de mulheres no perfil de liderança observada no experimento. A partir dessa análise, eles incluem exemplos mais diversos e equilibrados. Além disso, o monitoramento contínuo dos resultados permite identificar classificações incorretas e realizar ajustes no modelo. Essa prática melhora a qualidade dos dados e reduz a probabilidade de reprodução de vieses.